Лабораторна робота № 7

ДОСЛІДЖЕННЯ МЕТОДІВ НЕКОНТРОЬОВАНОГО НАВЧАННЯ

Мета роботи: використовуючи спеціалізовані бібліотеки та мову програмування Python дослідити методи неконтрольованої класифікації даних у машинному навчанні.

Хід роботи:

Завдання 2.1. Кластеризація даних за допомогою методу k-середніх

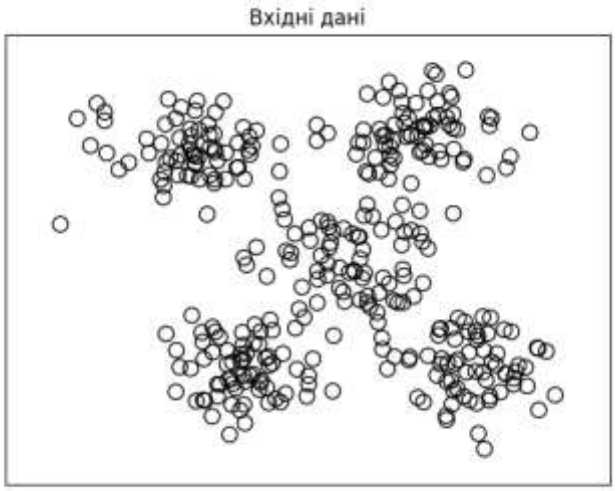

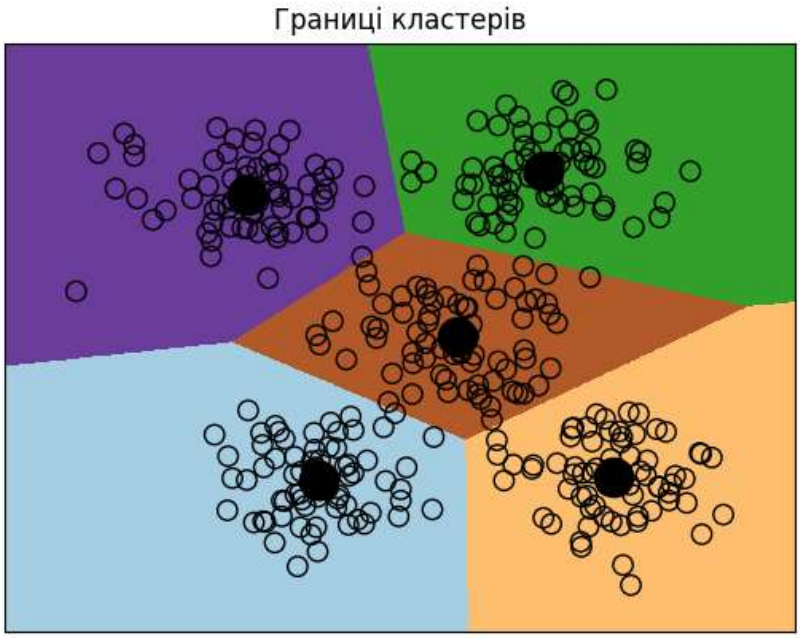

Лістинг:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn import metrics

X = np.loadtxt("data_clustering.txt", delimiter=",")

num_clusters = 5

plt.figure()
plt.scatter(X[:, 0], X[:, 1], marker='o', facecolors='none', edgecolors="black",
s=80)
x_min, x_max = X[:,0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:,1].min() - 1, X[:, 1].max()+1
plt.title("Вхідні дані")
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.xticks(())
plt.yticks(())

#plt.show()

kmeans = KMeans(init="k-means++", n_clusters=num_clusters, n_init=10)

kmeans.fit(X)

step_size = 0.01

x_min, x_max = X[:,0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:,1].min() - 1, X[:, 1].max()+1
x_vals, y_vals = np.meshgrid(np.arange(x_min, x_max, step_size), np.arange(y_min,
y_max, step_size))

output = kmeans.predict(np.c_[x_vals.ravel(), y_vals.ravel()])
output = output.reshape(x_vals.shape)
plt.figure()
plt.clf()
plt.imshow(output, interpolation='nearest', extent=(x_vals.min(), x_vals.max(),
y_vals.min(), y_vals.max()), cmap=plt.cm.Paired, aspect='auto', origin="lower")

plt.scatter(X[:, 0], X[:, 1], marker='o', facecolors='none', edgecolors="black",
s=80)

cluster_centers = kmeans.cluster_centers_
```

```
plt.scatter(cluster_centers[:, 0], cluster_centers[:, 1], marker='o', s=210,
linewidth=4, color='black', facecolors='black')
x_min, x_max = X[:,0].min() - 1, X[:, 0].max()+1
y_min, y_max = X[:,1].min() - 1, X[:, 1].max()+1

plt.title("Границі кластерів")
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.xticks(())
plt.yticks(())

plt.show()
```

Завдання 2.2. Кластеризація K-середніх для набору даних Iris

Лістинг:

```
from sklearn.svm import SVC
from sklearn.metrics import pairwise_distances_argmin
import numpy as np
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans

iris = load_iris()
X = iris['data']  # Завантаження даних із набору "iris"
y = iris['target']  # Завантаження цільових міток із набору "iris"

# Створення об'єкта KMeans з неправильними аргументами (потребує виправлення)
kmeans = KMeans(n_clusters=8, init='k-means++', n_init=10, max_iter=300,
tol=0.0001,
                verbose=0, random_state=None, algorithm='auto')

kmeans = KMeans(n_clusters=5)  # Ініціалізація KMeans з 5 кластерами

kmeans.fit(X)  # Навчання моделі KMeans на даних X

y_kmeans = kmeans.predict(X)  # Прогнозування кластерів для X

# Візуалізація даних із кольоровими мітками кластерів
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, s=50, cmap='viridis')
centers = kmeans.cluster_centers_  # Отримання центрів кластерів
plt.scatter(centers[:, 0], centers[:, 1], c='black', s=200, alpha=0.5)  #
Візуалізація центрів кластерів

# Визначення функції для пошуку кластерів
```

```python
def find_clusters(X, n_clusters, rseed=2):
    rng = np.random.RandomState(rseed)  # Створення об'єкта генератора випадкових чисел
    i = rng.permutation(X.shape[0])[:n_clusters]  # Випадковий вибір початкових центрів
    centers = X[i]  # Ініціалізація центрів кластерів
    while True:
        # Присвоєння кожній точці найближчого центру кластера
        labels = pairwise_distances_argmin(X, centers)

        # Обчислення нових центрів як середнє значення точок у кожному кластері
        new_centers = np.array([X[labels == i].mean(0) for i in range(n_clusters)])

        # Перевірка, чи змінилися центри; якщо ні, припинити цикл
        if np.all(centers == new_centers):
            break
        centers = new_centers  # Оновлення центрів
    return centers, labels  # Повернення центрів і міток

centers, labels = find_clusters(X, 3)  # Виклик функції для пошуку 3 кластерів
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')  # Візуалізація з новими мітками
plt.show()

centers, labels = find_clusters(X, 3, rseed=0)  # Виклик функції з іншим значенням rseed
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')  # Візуалізація результатів
plt.show()

# Прогнозування кластерів за допомогою KMeans з 3 кластерами
labels = KMeans(3, random_state=0).fit_predict(X)
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap='viridis')  # Візуалізація кластерів
plt.show()
```

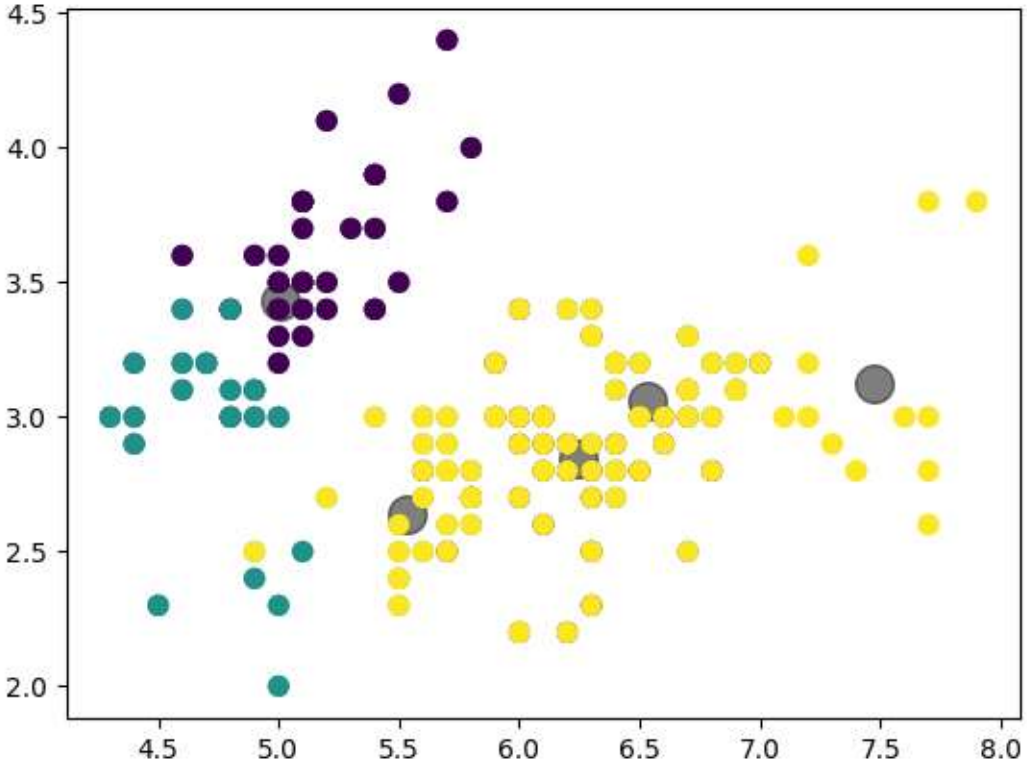
4.5
4.0
3.5
3.0
2.5
2.0
4.5
5.0
5.5
6.0
6.5
7.0
7.5
8.0

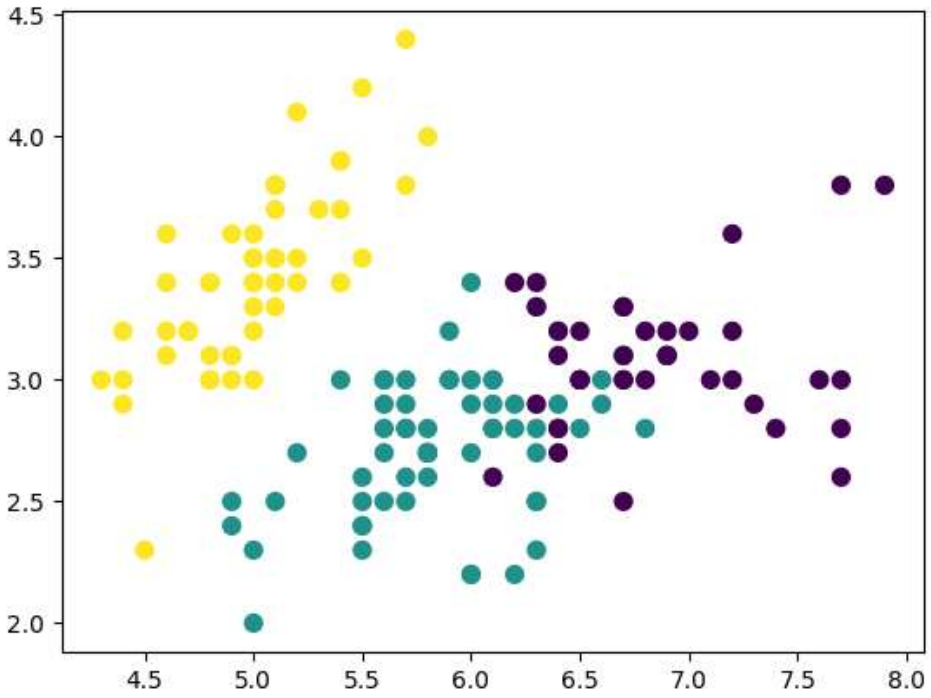
4.5
4.0
3.5
3.0
2.5
2.0
4.5
5.0
5.5
6.0
6.5
7.0
7.5
8.0

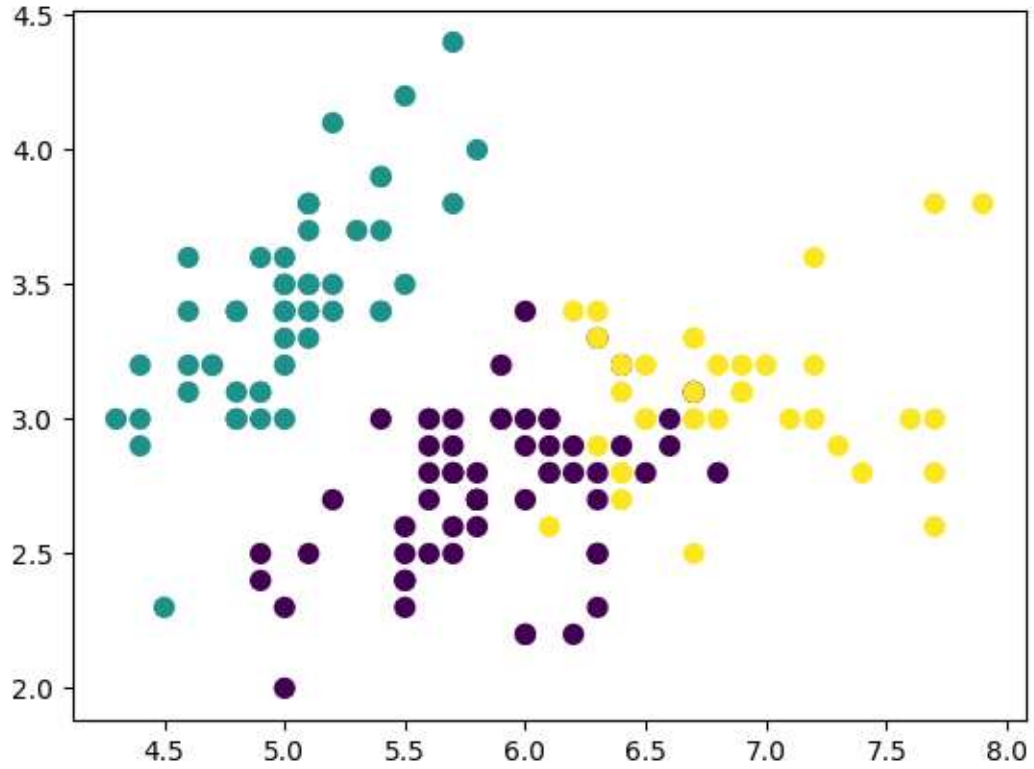

Завдання 2.3. Оцінка кількості кластерів з використанням методу зсуву середнього

Лістинг:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import MeanShift, estimate_bandwidth
from itertools import cycle

X = np.loadtxt("data_clustering.txt", delimiter=",")

bandwidth_X = estimate_bandwidth(X, quantile=0.1, n_samples=len(X))

meanshift_model = MeanShift(bandwidth=bandwidth_X, bin_seeding=True)
meanshift_model.fit(X)

cluster_centers = meanshift_model.cluster_centers_
print("clusters centers: \n", cluster_centers)

labels = meanshift_model.labels_
```

```
num_clusters = len(np.unique(labels))
print("\n Number of clusters in input data = ", num_clusters)

plt.figure()
markers = 'o*xvs'
for i, marker in zip(range(num_clusters), markers):
    plt.scatter(X[labels==i, 0], X[labels==i, 1], marker=marker, color='black')

    cluster_center = cluster_centers[i]
    plt.plot(cluster_center[0], cluster_center[1], marker='o',
markerfacecolor='black', markeredgecolor='black', markersize=15)
    plt.title("Кластери")
    plt.show()
```

Виконання програми:

```
[Running] python -u "d:\ztu\KURS4\ai\Lab7\LR_4_task_3.py"
clusters centers:
 [[2.95568966 1.95775862]
 [7.20690909 2.20836364]
 [2.17603774 8.03283019]
 [5.97960784 8.39078431]
 [4.99466667 4.65844444]]

 Number of clusters in input data =  5

[Done] exited with code=0 in 51.719 seconds
```

Графіки:

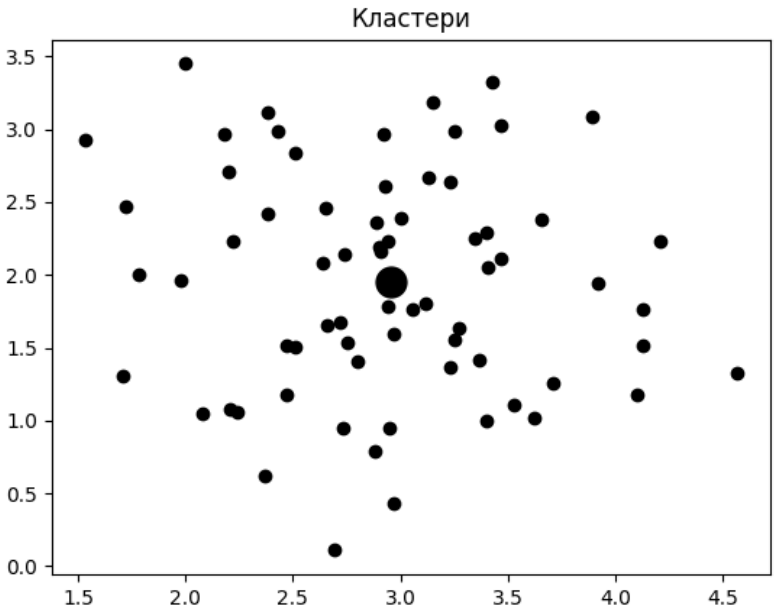

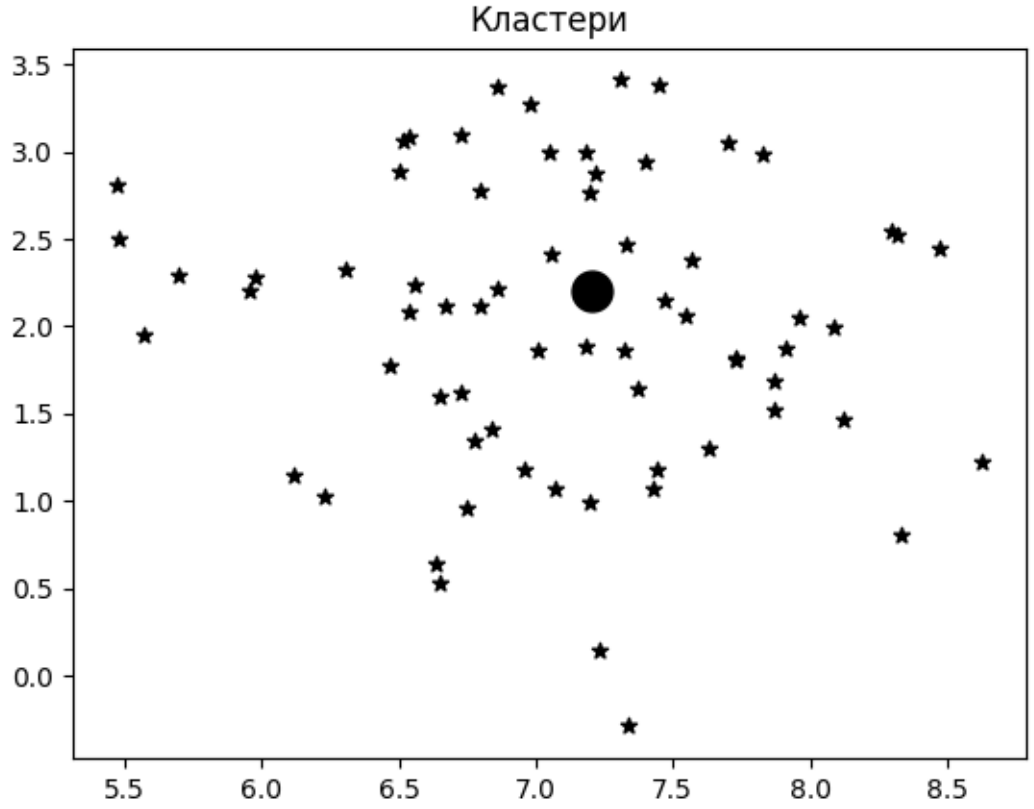
Кластери
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
5.5
6.0
6.5
7.0
7.5
8.0
8.5

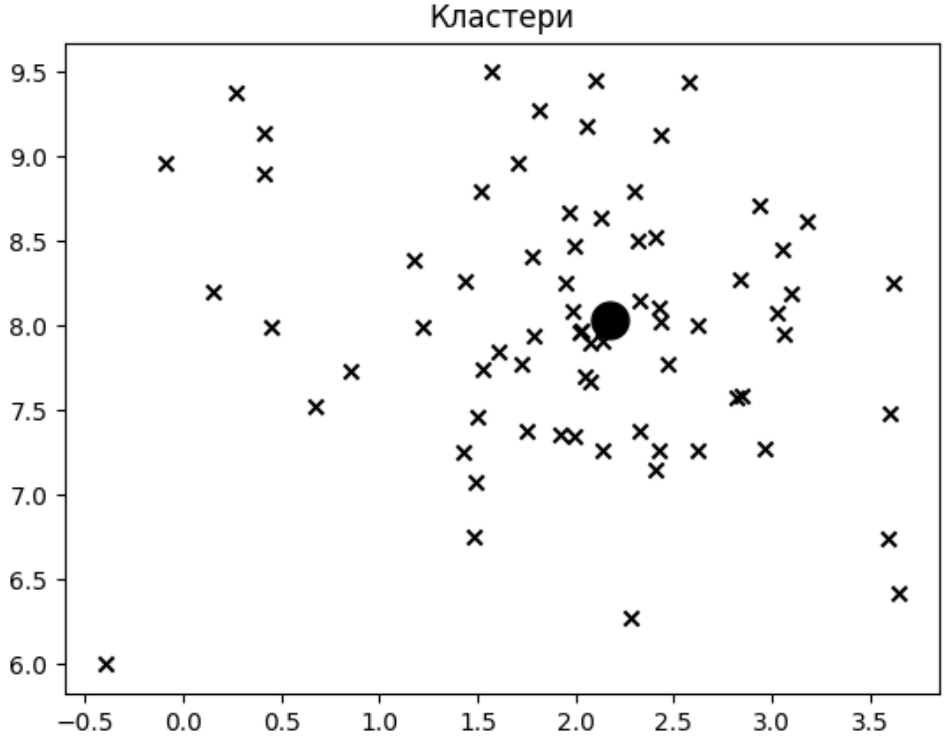
Кластери
9.5
9.0
8.5
8.0
7.5
7.0
6.5
6.0
−0.5
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5

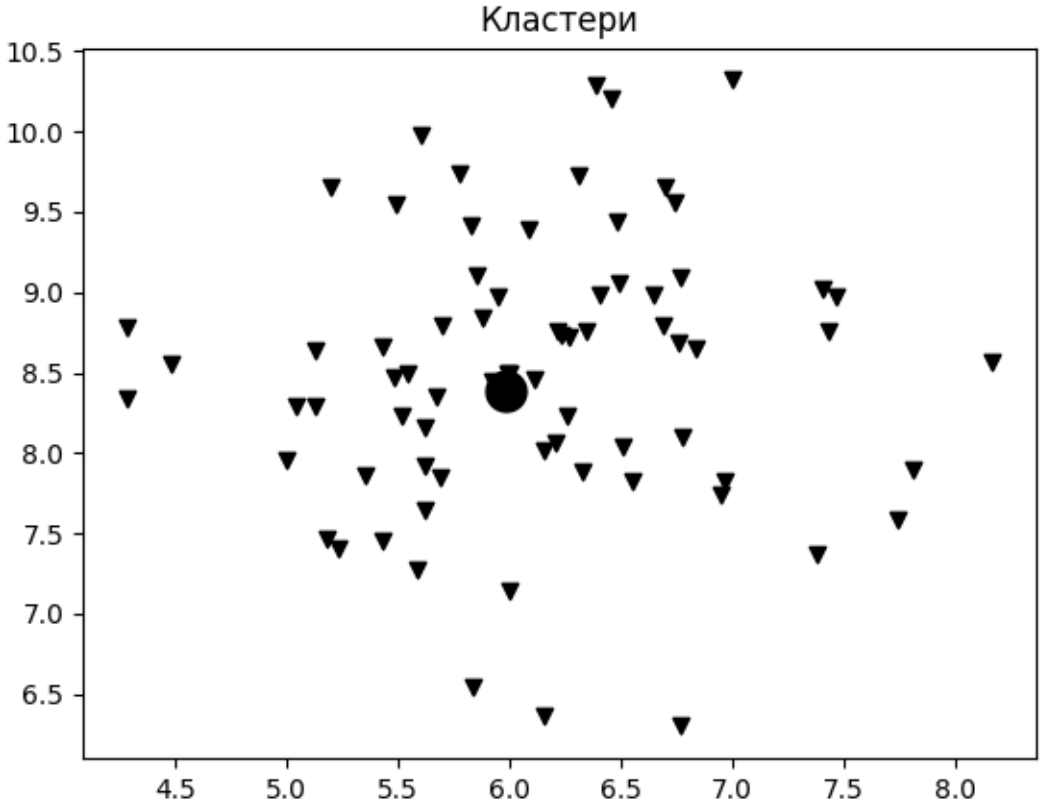
Кластери
10.5
10.0
9.5
9.0
8.5
8.0
7.5
7.0
6.5
4.5
5.0
5.5
6.0
6.5
7.0
7.5
8.0

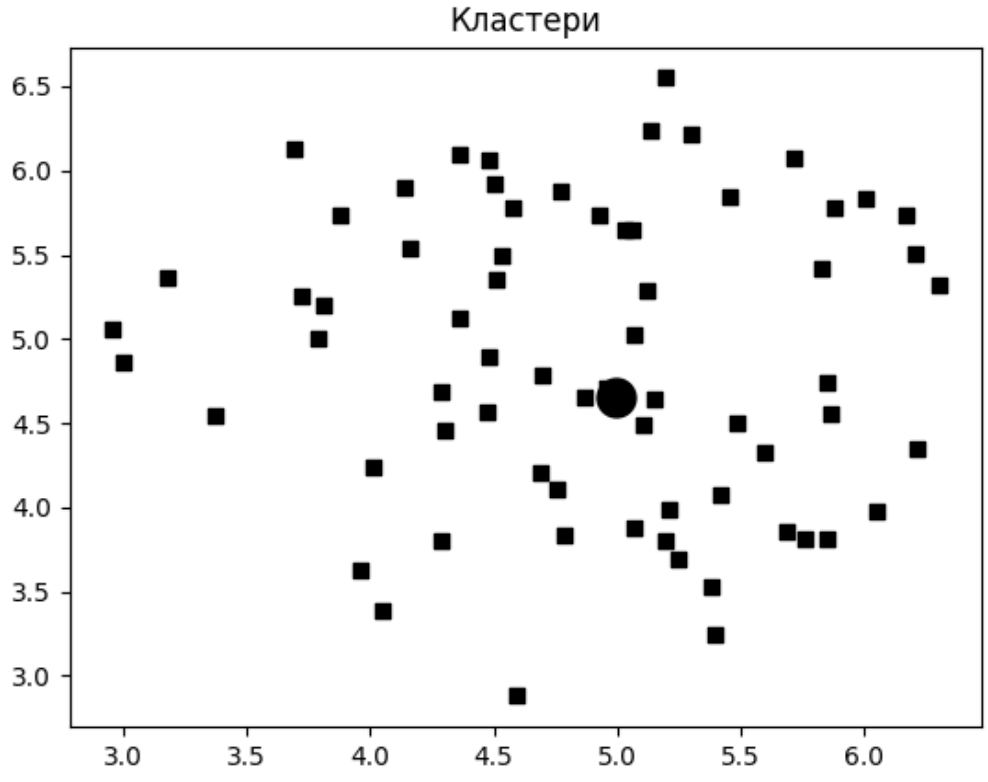
Кластери
6.5
6.0
5.5
5.0
4.5
4.0
3.5
3.0
3.0
3.5
4.0
4.5
5.0
5.5
6.0

Завдання 2.4. Знаходження підгруп на фондовому ринку з використанням моделі поширення подібності

Файл `company_symbol_mapping.json` було завантажено з відкритого репо на гіті тому що його чомусь не було в додатках до лаби на моменті її виконання, дані з файлу було перенесено в код.

Також крім цього бібліотеки from matplotlib.finance import quotes_historical_yahoo_ochl as quotes_yahoo більше не існує, і її прямі аналогі на разі також не дієздані, тому було обрано трохи інший підхід, можливо він не побачив всіх даних, але це ледь не єдиний метод який вдалось знайти.

Лістинг:

```
import datetime
import numpy as np
import matplotlib.pyplot as plt
import yfinance as yf
from sklearn import covariance, cluster

company_symbols_map = {
    "TOT": "Total",
    "XOM": "Exxon",
    "CVX": "Chevron",
    "COP": "ConocoPhillips",
    "VLO": "Valero Energy",
    "MSFT": "Microsoft",
    "IBM": "IBM",
    "TWX": "Time Warner",
    "CMCSA": "Comcast",
    "CVC": "Cablevision",
    "YHOO": "Yahoo",
    "DELL": "Dell",
    "HPQ": "HP",
    "AMZN": "Amazon",
    "TM": "Toyota",
    "CAJ": "Canon",
    "MTU": "Mitsubishi",
    "SNE": "Sony",
    "F": "Ford",
    "HMC": "Honda",
    "NAV": "Navistar",
    "NOC": "Northrop Grumman",
    "BA": "Boeing",
    "KO": "Coca Cola",
```

```
    "MMM": "3M",
    "MCD": "Mc Donalds",
    "PEP": "Pepsi",
    "MDLZ": "Kraft Foods",
    "K": "Kellogg",
    "UN": "Unilever",
    "MAR": "Marriott",
    "PG": "Procter Gamble",
    "CL": "Colgate-Palmolive",
    "GE": "General Electrics",
    "WFC": "Wells Fargo",
    "JPM": "JPMorgan Chase",
    "AIG": "AIG",
    "AXP": "American express",
    "BAC": "Bank of America",
    "GS": "Goldman Sachs",
    "AAPL": "Apple",
    "SAP": "SAP",
    "CSCO": "Cisco",
    "TXN": "Texas instruments",
    "XRX": "Xerox",
    "LMT": "Lookheed Martin",
    "WMT": "Wal-Mart",
    "WBA": "Walgreen",
    "HD": "Home Depot",
    "GSK": "GlaxoSmithKline",
    "PFE": "Pfizer",
    "SNY": "Sanofi-Aventis",
    "NVS": "Novartis",
    "KMB": "Kimberly-Clark",
    "R": "Ryder",
    "GD": "General Dynamics",
    "RTN": "Raytheon",
    "CVS": "CVS",
    "CAT": "Caterpillar",
    "DD": "DuPont de Nemours"
}

symbols, names = np.array(list(company_symbols_map.items())).T

start_date = datetime.datetime(2003, 7, 3)
end_date = datetime.datetime(2007, 5, 4)

quotes = []
valid_symbols = []

for symbol in symbols:
```

```
    try:
        stock_data = yf.Ticker(symbol).history(start=start_date, end=end_date)
        if stock_data.empty:
            print(f"{symbol}: No data found")
        else:
            quotes.append(stock_data)
            valid_symbols.append(symbol)
    except Exception as e:
        print(f"{symbol}: Error fetching data - {e}")

min_length = min(len(quote) for quote in quotes)
quotes = [quote.iloc[:min_length] for quote in quotes]

opening_quotes = np.array([quote['Open'].values for quote in quotes],
dtype=np.float64)
closing_quotes = np.array([quote['Close'].values for quote in quotes],
dtype=np.float64)

quotes_diff = closing_quotes - opening_quotes

X = quotes_diff.copy().T
X /= X.std(axis=0)

edge_model = covariance.GraphicalLassoCV()

with np.errstate(invalid='ignore'):
    edge_model.fit(X)

_, labels = cluster.affinity_propagation(edge_model.covariance_)
num_labels = labels.max()

print('\nClustering of stocks based on difference in opening and closing
quotes:\n')
for i in range(num_labels + 1):
    cluster_symbols = np.array(valid_symbols)[labels == i]
    cluster_names = np.array(names)[np.isin(symbols, cluster_symbols)]
    print("Cluster", i+1, "==>", ', '.join(cluster_names))
```

Виконання:

```
[Running] python -u "d:\ztu\KURS4\ai\Lab7\LR_4_task_4.py"
$TOT: possibly delisted; no timezone found
TOT: No data found
$CVC: possibly delisted; no price data found  (1d 2003-07-03 00:00:00 -> 2007-05-04 00:00:00)
CVC: No data found
$YHOO: possibly delisted; no timezone found
YHOO: No data found
$DELL: possibly delisted; no price data found  (1d 2003-07-03 00:00:00 -> 2007-05-04 00:00:00) (Yahoo error = "Data doesn't exist for startDate = 1057204800, endDate = 1178251200")
DELL: No data found
$CAJ: possibly delisted; no timezone found
CAJ: No data found
$MTU: possibly delisted; no price data found  (1d 2003-07-03 00:00:00 -> 2007-05-04 00:00:00)
MTU: No data found
$SNE: possibly delisted; no timezone found
SNE: No data found
$NAV: possibly delisted; no timezone found
NAV: No data found
$UN: possibly delisted; no timezone found
UN: No data found
$RTN: possibly delisted; no timezone found
RTN: No data found

Clustering of stocks based on difference in opening and closing quotes:

Cluster 1 ==> Exxon, Chevron, ConocoPhillips, Valero Energy
Cluster 2 ==> Toyota, Ford, Honda, Boeing, Mc Donalds, Apple, SAP, Caterpillar
Cluster 3 ==> Kraft Foods
Cluster 4 ==> Coca Cola, Pepsi, Kellogg, Procter Gamble, Colgate-Palmolive, Kimberly-Clark
Cluster 5 ==> Time Warner, Comcast, Marriott, Wells Fargo, JPMorgan Chase, AIG, American express, Bank of America, Goldman Sachs, Xerox, Wal-Mart, Home Depot, Ryder, DuPont de Nemours
Cluster 6 ==> Microsoft, IBM, HP, Amazon, 3M, General Electrics, Cisco, Texas instruments
Cluster 7 ==> Northrop Grumman, Lookheed Martin, General Dynamics
Cluster 8 ==> Walgreen, CVS
Cluster 9 ==> GlaxoSmithKline, Pfizer, Sanofi-Aventis, Novartis

[Done] exited with code=0 in 19.161 seconds
```

GIT: https://github.com/Alhim616/AI_Labs_Yanushevych